

Softvéry na detekciu potencionálnych rizík implementované v automobiloch*

Michal Januška

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xjanuskam@stuba.sk

5.10. 2021

Abstrakt

Žijeme v dobe, kde už je vlastníctvo automobilu komoditou. Tieto stroje sú nám veľkou výpomocou či už pri výkone práce alebo pri voľnočasových aktivitách. Aj keď sa na prvý pohľad môže zdať, že automobily so sebou prinášajú samé výhody, nastávajú aj také situácie kedy sa toto vozidlo môže vymknúť kontrole vodiča a môže dôjsť k veľmi nebezpečným situáciám alebo až k smrteľným nehodám. V takýchto situáciách nastupujú rôzne zabudované softvéry, ktoré majú za úlohu včas detekovať hroziace riziko a vykonať všetko pre jeho zabránenie s dôrazom na čo najmenšie ohrozenie posádky automobilu ale aj vonkajšieho prostredia. Tieto softvéry fungujú na báze umelej inteligencie a machine learningu. V tejto práci sa venujem predstaveniu týchto softvérov z rôznych aspektov a ich funkcionalite ktorá spočíva v modelovaní postupov riešení pri rizikových situáciách.

1 Úvod

Zameranie tejto práce je pomerne široké, preto sa ho budem snažiť interpretovať čo najjednoduchšie a najstručnejšie. Hneď v sekcii 2 si predstavíme riziká ktoré môžu nastať pri vedení automobilu alebo aj pri automobile ktorý nie je práve v pohybe. V nasledujúcej sekcii 3 si predstavíme softvéry a pomocné komponenty ktoré majú za úlohu sa s týmito situáciami vysporiadať a urobíme ich podrobný rozbor. Niektoré z týchto komponentov ešte momentálne nie je implementovaných v bežných automobiloch, ale vývojári sa ich snažia dokončiť čo najrýchlejšie a následne vyslať na trh. Budeme sa zaoberať vytváraním modelov daných situácií a ukážeme si ich priebeh od začiatku až do konca. V tejto práci nebudem poukazovať len na výhody týchto softvérov a zariadení, ale budem uvádzať aj nevýhody a ich potencionálne odstránenie. Rozbor jednotlivých softvérov a komponentov bude obohatený o rôzne grafy a vývojové diagramy, pre lepšie pochopenie danej problematiky. Celá práca bude zhrnutá v sekcii 5, kde sa podelím o svoj osobný názor a urobím jej kompletný výstup.

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2021/22, vedenie: PhD. Ing. Fedor Lehocki

2 Problematika

Pokroky v automobilovom priemysle sú veľmi citeľné a s dostupnosťou moderných technológií napredujú bleskovou rýchlosťou. Ako príklad nám slúži autopilot, ktorý bol prvotne implementovaný v autách značky Tesla a momentálne už máme na trhu veľké množstvo automobilových firiem ktoré taktiež implementovali túto funkcionálnosť do svojich áut. Autopilot ako taký, je pomerne nová funkcionálnosť a preto s jeho nástupom prišli aj situácie v ktorých nezareagoval adekvátne alebo aj vôbec a tým pádom spôsobil závažné nehody. Zoberme si ako príklad rok 2018 [1], kedy autopilotom vedené vozidlo značky Uber zrazilo chodca a spôsobilo mu vážnejšie zranenia. Aj napriek rozvoju autopilota, sme sa ešte nedostali do takej fázy aby bol rozšírený do väčšiny áut, najmä kvôli jeho cenovej dostupnosti, a preto drvivá väčšina obyvateľstva riadi svoje auto manuálne. Tu zasa prichádzajú ďalšie faktory ako napríklad fyzický a psychický stav vodiča a posádky auta, ktoré môžu náhle zmeniť pokojnú situáciu vedenia vozidla na kritickú. Ide napríklad o náhlu zmenu zdravotného stavu šoféra, kedy stráca kontrolu nad vozidlom a ohrozuje tým svoju posádku a taktiež aj vonkajšie okolie. Aby sa stihlo včas zabrániť takýmto situáciám, firmy prichádzajú s rôznymi softvérmi a komponentami ktorých funkcia je detekovať, vyhodnotiť a vyriešiť danú rizikovú situáciu.

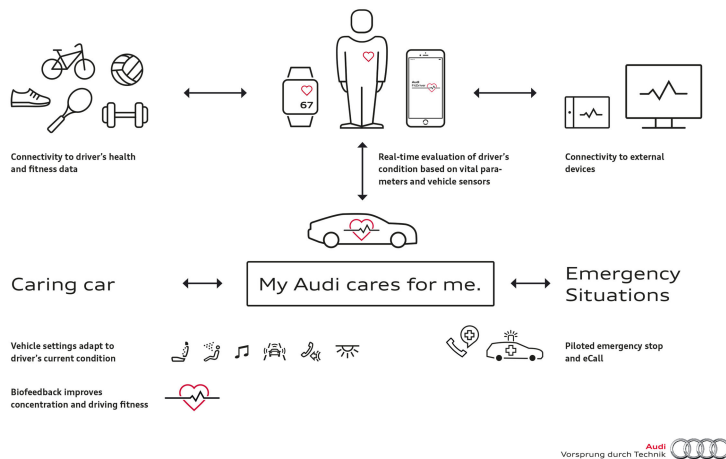
3 Predstavenie softvérov a komponentov

V predchádzajúcej sekcii 2 sme boli oboznámení s rizikovými situáciami ktoré môžu nastať. V tejto sekcii si predstavíme rôzne softvéry a komponenty ktoré majú týmto situáciám zabrániť. Tieto komponenty sú strategicky osadené vo výhodných pozíciách automobilu, aby dokázali pracovať bez akéhokoľvek obmedzenia.

3.1 Audi Fit Driver [1]

Audi Fit Driver je projekt od spoločnosti Audi, ktorý má za pomoci získaných informácií o fyzickom a psychickom stave vodiča, ale taktiež aj stave vonkajšieho prostredia, ako napríklad stav počasia alebo hustota dopravy, upraviť prostredie automobilu tak, aby sa znížila pravdepodobnosť vzniku nejakého rizika. Ak je zdravotný stav vodiča natoľko zlý, že stráca kontrolu nad vozidlom, aktivujú sa softvéry ktoré dokážu zavolať vodičovi záchranku ale taktiež bezpečne dopraviť automobil na najbližšie stojisko. Za zber týchto informácií zodpovedajú napríklad hodinky alebo náramok, ktorý komunikuje s vonkajšími servermi ale taktiež aj so softvérmi zabudovanými priamo v automobile. Ak je napríklad zaznamenaná zvýšená hladina stresu, ktorá sa môže preukázať zvýšeným pulzom šoféra, Audi Fit Driver môže upraviť hlasitosť a štýl hudby ktorú vodič počúva, alebo v prípade hustej dopravy ponúkne alternatívnu, menej stresujúcu trasu.

Audi FitDriver – Features



Obr. 1: Model funkcionality komponentov Audi Fit Driver [1]

Na obrázku 2 môžeme jasne vidieť, ako prebieha monitorovanie pasažiera v reálnom čase. Môžeme pozorovať, že riešenie danej situácie vyplýva z jej závažnosti. Napriek tomu, že tento projekt vyzerá byť veľmi dobre navrhnutý, sú tu isté faktory ktoré, by mohli viesť k jeho zlyhaniu. Jedným z nich je napríklad výdrž batérie hodín, ktorá môže mať za výsledok pozastavenie výmeny informácií medzi servermi a samotným automobilom a preto v prípade rizikovej situácie, nemusia byť softvéry na jej riešenie plne dostupné. Tento problém by sa dal potencióálne odstrániť jednoduchým warningom, ktorý by upozornil vodiča aby si dané zariadenie čo najskôr dobil, aby bolo plne funkčné v prípade rizikových situácií.

3.2 Passenger monitoring using AI radar [2]


Passenger monitoring system je veľmi dôležitým softvérom, ktorý má za úlohu rozpoznávať živé objekty a ich počet v automobile. Na prvý pohľad sa nám môže zdať zámer tohto softvéru nejasný, no zoberme si veľmi častú situáciu ktorá nastáva najmä v letných mesiacoch. Podľa skupiny Kids and Cars prišlo v automobiloch od roku 1990 až po súčasnosť o život skoro 1000 detí na následky prehriatia organizmu alebo naopak umrznutia. A to nehovoriac ešte o nespočetnom množstve domácich zvierat. Ľudom sa často stáva že v rýchlom okamihu zabudnú svoje dieťa alebo domáce zviera v aute a niekedy stačí naozaj chvíľa a už je neskoro na ich záchranu. Toto je dôvod prečo bol navrhnutý Passenger monitoring system. Budem sa zaoberať druhom systému, ktorý na túto detekciu využíva radar umelej inteligencie. Prečo práve radar? Odpoveď je jasná. Radar na rozdiel od ultrazvukových senzorov ne stráca výkonnosť pri prechode viacerými materiálmi, tým pádom môže byť umiestnený kdekoľvek v automobile a stále mať 100% výsledok pri zbere dát. Ďalšou možnosťou je aj kamerový systém ktorý by na základe pohybu dokázal zbierať potrebné údaje. Táto možnosť je síce lákavá, ale jej nevýhodou je narušenie súkromia vlastníka automobilu.

3.2.1 Presence-Absence Detection Algorithm (PAD)

Toto je algoritmus bol implementovaný do radaru umelej inteligencie na detekciu živých organizmov v automobiloch. Spočíva na báze machine-learningu a výsledky ktoré prináša musia byť 100%-tné, pretože akákoľvek malá chyba môže pripraviť niekoho alebo niečo o život. Tento algoritmus nemá za úlohu zisťovať pozíciu a druh organizmov, ale iba rozlíšiť či sa v automobile nachádza živý organizmus. Rozlišuje to na základe najväčšieho rozdielu medzi živým organizmom a neživými vecami, dýchacích cyklov. Ak sú niekde v automobile zaznamenané dýchacie cykly, algoritmus okamžite vyšle signál o prítomnosti živého organizmu. Tento algoritmus bol testovaný pri 65 rôznych scenároch a každý z nich trval v priemere viac ako 3 minúty. Radarom bolo zozbieraných okolo 300 minút čistých dát, ktoré algoritmus prešiel a vyhodnotil všetky bez jedinej chyby.

3.2.2 Passenger Counting Algorithm

PCA je ďalším algoritmom implementovaným v danom radare ktorý má za úlohu detekovať počet a rozmiestnenie osôb v automobile. Počas testovania bolo zozbieraných 192 minút dát pri 32 možných situáciach. Pri týchto testoch boli použité 3 machine learning algoritmy. Sú to Random Forest (RF), K-Nearest Neighbors (KNN) a Support Vector Machine (SVM). Každý z nich prechádzal zozbieranými dátami a na grafe môžeme vidieť ich konečnú presnosť. A môžeme s istotou povedať, že algoritmus Support Vector Machine priniesol najlepšie výsledky.



Obr. 2: Graf vyobrazujúci presnosť algoritmov pre rôzne sedadlá [2]

3.3 Heart rate monitoring system [3]

3.4 Healthcare Monitoring System Inside Self-driving Smart Car in 5G Cellular Network [4]

4 Modelovanie situácií

5 Záver

Literatúra

- [1] Self driving and self diagnosing: With emerging technology, your car may soon serve not only as personal chauffeur and entertainment center but as a health advisor too. 9(4):4–7, July 2018.
- [2] Hajar Abedi, Clara Magnier, and George Shaker. Passenger monitoring using AI-powered radar. IEEE, August 2021.
- [3] R. M. Fouad, A. Onsy, and Osama A. Omer. Improvement of driverless cars' passengers on board health and safety, using low-cost real-time heart rate monitoring system. IEEE, September 2018.
- [4] Md. Ibrahim Mamun, Afroza Rahman, Md. Abdul Khaleque, M. F. Mridha, and Md. Abdul Hamid. Healthcare monitoring system inside self-driving smart car in 5g cellular network. In *2019 IEEE 17th International Conference on Industrial Informatics (INDIN)*, volume 1, pages 1515–1520, 2019.